

Análisis de Transiciones MLOps: Grupo D

Pipeline de Entrenamiento Continuo (CT) en Producción

Este análisis técnico examina el flujo de automatización de reentrenamiento continuo, desde la orquestación inicial hasta la entrega del modelo optimizado. Presentado con fines académicos en el contexto de la asignatura MLOps & AI BI, se describe el bloque Orchestrator → Data Retrieval → Data Validation → Model Training → Model Validation → Model Handover: su arquitectura, herramientas y comportamiento bajo condiciones adversas.

Arquitectura del Pipeline: Orquestación y Flujo de Datos



El Desencadenante

El Orchestrator inicia el flujo enviando una orden de ejecución mediante un Payload JSON. La activación puede basarse en programación temporal (Cron) o eventos externos como la detección de data drift.

Extracción y Validación

Data Retrieval extrae snapshots versionados del Feature Store. La etapa de validación constituye un punto crítico: si los datos no superan las pruebas estadísticas, el pipeline se detiene automáticamente.

Análisis Técnico: Transiciones Críticas del Flujo

1

Data Retrieval → Validation

Movimiento de artefactos de datos snapshot versionados mediante DVC (Data Version Control), garantizando la reproducibilidad completa del experimento.

2

Validation → Training

Fujo condicional implementado con Great Expectations: únicamente los datos que superan las validaciones de esquema y distribuciones pasan al entrenamiento.

Mecanismos de Resiliencia

Implementación de chequeos que monitorean la calidad de los datos en tiempo real. Cuando se detecta baja calidad o drift significativo, se aborta el entrenamiento automáticamente y se genera una alerta SLA escalada al equipo de ML.

Entrenamiento, Validación y Respuestas Transversales



Training → Validation

Transferencia de binarios del modelo en contenedores Docker mediante Kubeflow, asegurando la reproducibilidad del entorno de ejecución.



Validation → Handover

Comparación automática de métricas entre el modelo candidato y el baseline. Generación de metadatos completos para auditoría.

Generación de Metadatos

Todas las transiciones del Grupo D registran metadatos (logs, métricas, linaje de datos) en el ML Metadata Store (MLflow), permitiendo auditoría completa y trazabilidad.

Gestión de Fallas 3:00 AM

El pipeline queda bloqueado en el punto de falla y mantiene la última versión de modelo operacional. El equipo recibe notificaciones automáticas para intervención manual.

Resumen de Transiciones y Características de Resiliencia

Transición	Tipo	Dato Transferido	Herramienta	Modo de fallo	Mitigación
Orchestrator → Retrieval	Trigger	Configuración (JSON)	Apache Airflow	Mala configuración	Alerta temprana
Retrieval → Validation	Datos	Dataset	DVC	Partición incompleta/datos corruptos	Detección temprana
Validation → Training	Datos	Datos validados	TFDV	Out of memory	Guardar checkpoints del entrenamiento
Training → Validation	Artefacto	Modelo (.pkl/.pb)	MLFlow tracking	Modelo nuevo rinde peor que actual	Abortar pipeline y mantener modelo anterior
Validation → Handover	Artefacto	Métricas/Status	MLflow registry	Conflictos de versiones	Mantener último modelo bueno y hacer rollback